

通过零点约束稳定方程学习

摘要

符号回归旨在从数据中发现可解释的数学表达式。方程学习器 (Equation Learner, EQL) 是一种基于梯度的方法, 具有较强的拟合能力和表达潜力; 然而, 随着模型复杂度增加, 它常会激活冗余算子, 导致表达式过度复杂并使方程恢复不稳定。我们分析了由零点处不为零的算子引起的梯度残留问题: 这类问题会阻止理想稀疏表达式在训练中成为稳定吸引子, 并使训练偏向不必要的复杂结构, 从而导致精确恢复在实践中高度不可靠。为解决这一问题, 我们提出 EQL-Z, 一种结构可控的符号回归框架。EQL-Z 通过零点一致的算子变换施加零点约束, 以消除静默路径上的残留梯度; 同时, 它执行由小到大的结构搜索, 在复杂度惩罚的验证分数约束下, 从紧凑种子结构逐步增长网络深度和宽度。在选择紧凑结构后, 我们可选地应用 BFGS 微调来优化系数。合成数据集和真实世界数据集上的实验表明, 相比原始 EQL, EQL-Z 显著提升了精确方程恢复能力以及分布内/分布外泛化性能, 其表现接近领先的符号回归基线。代码可见 <https://github.com/Caaaaa-a/EQL-Z>。

1 引言

符号回归 (symbolic regression, SR) 旨在从数据中恢复结构紧凑且可解释的数学表达式, 并在物理建模和科学发现中发挥着重要作用 [5, 6, 15, 26, 31]。近年来, 神经网络被引入这一领域, 推动了神经符号回归这一研究方向的发展。方程学习器 (Equation Learner, EQL) [20] 是该范式中的代表性方法: 它将可微符号算子 (例如 $\sin$ 、 $\cdots$ 、 $\exp$) 集成到神经网络中, 并结合稀疏正则化, 引导模型从数据中学习解析表达式。EQL 具有较强的结构灵活性、表达能力和拟合效率, 使其能够在复杂函数建模任务中平衡精度与可解释性。然而, 当候选网络逐渐过参数化时, EQL 往往会激活冗余算子, 导致表达式不必要地复杂, 并使精确方程恢复变得不稳定。

为更好地理解这一冗余问题的重要来源, 我们设计了一个具有唯一解析解的简单玩具任务, 并观察到 EQL 在训练过程中会逐渐偏离真实结构, 同时冗余项被激活。进一步的梯度分析表明, 当某些算子在零点处不为零时, 即使其输入连接系数为零, 它们也可能诱导非零梯度, 从而使这些算子在优化过程中被错误激活。因此, 即便目标表达式可由网络表示, 在残差消失之前, 对应的稀疏参数配置也可能无法作为稳定的训练吸引子。

为解决这一由残留梯度引起的不稳定性, 我们提出 EQL-Z, 一种用于符号神经网络的结构可控训练框架。EQL-Z 从两个互补角度处理冗余激活失败: 一方面减少暴露给优化过程的冗余路径数量, 另一方面缓解候选结构中仍然存在的冗余路径所带来的残留梯度效应。这两个角度由两个关键组件实现:

1. **由小到大的结构搜索。** EQL-Z 从一个紧凑的种子架构出发, 通过局部宽度/深度修改迭代扩展网络, 并根据带有符号复杂度惩罚的验证分数接受新结构。与训练单个大型固定网络相比, 这种增量策略减少了不必要的算子路径, 并降低了收敛到过度复杂局部最优的风险。
2. **零点约束。** EQL-Z 使用零点一致变换, 使符号算子满足 $\Lambda(0) = 0$, 从而确保连接权重为零

且算子输入为零的冗余路径产生零输出，并且不会接收到仅由算子在原点处非零响应所导致的残留梯度。

这两个组件是互补的：由小到大的搜索在架构层面减少冗余结构，而零点约束在优化层面稳定剩余的冗余路径。二者结合后，在保留 EQL 可解释性的同时显著提升精确公式恢复能力，并相较原始 EQL 在分布内和分布外泛化上取得明显改进。

2 相关工作

符号回归 (SR) 旨在从数据中恢复结构紧凑且可解释的数学表达式，并已广泛应用于物理建模和科学发现 [21, 19, 2, 30]。经典方法主要依赖对符号结构的显式搜索，大体可分为基于进化的方法和基于强化学习 (reinforcement learning, RL) 的方法。进化方法以遗传编程 (genetic programming, GP) [29, 10] 为代表，它通过模拟自然进化来生成候选表达式，常见扩展包括 GOMEA [33] 和语义反向传播 GP (semantic backpropagation GP, SBP-GP) [24]。基于 RL 的方法则将表达式构造建模为一个状态-动作过程，并通过奖励驱动搜索，代表性方法包括 DSR [25] 和 NGGP [22]。尽管这两类方法在结构搜索的设计理念上有所不同，但它们通常都需要大量启发式调参，并且搜索效率较低，难以满足复杂任务中高效表达式建模的需求。

为克服这些局限，近年来的研究将神经网络引入 SR，形成了两条主要研究路线：基于 Transformer 的生成式符号回归，以及用于符号回归的神经网络 [17, 11]。前者利用语言模型直接生成满足语法约束的表达式结构，代表性工作通常基于 Transformer 式架构 [16, 28, 3, 9, 1]。然而，这类方法的生成行为与预训练和固定解码策略紧密绑定，缺乏对数据难度的动态适应能力，也难以以渐进、数据驱动的方式构造复杂表达式。

相比之下，以方程学习器 (EQL) 为代表的符号回归神经网络，将可微符号算子（例如加法、乘法、三角函数）直接嵌入神经架构。这一范式结合了神经网络的高效优化能力和符号模型的可解释性，使训练过程中能够自然进行表达式压缩和结构稀疏控制，从而对搜索过程提供更强的控制。后续变体进一步增强了该方法族的表达能力和结构可控性：EQL $\div$ [27] 引入可微除法和基于外推的验证以改进函数建模；iEQL [34] 结合 L_0 正则化和先验知识，引导更可控的结构并支持更丰富的算子（例如对数和除法）；OccamNet [7] 和 MathONet [36] 通过强化连接稀疏性来提高灵活性；CONSOLE [14] 以及 DYSYMNET [35] 则侧重于提升结构可达性和收敛效率。

尽管 EQL 及其衍生方法具有较强的表示能力和拟合性能，实践中仍可能出现表达式过度复杂和训练不稳定的问题。已有研究报告了 EQL 方法族中的梯度不稳定性以及陷入较差局部极小值的倾向，这会导致公式不必要地复杂并降低可解释性 [25, 34]。我们进一步观察到，即使目标函数可由当前架构精确表示，优化轨迹也可能偏离真实结构，这表明其缺乏结构稳定性。其中一个原因是，现有工作主要强调连接稀疏性（例如剪枝策略），却很大程度上忽略了激活稀疏性和梯度传播如何共同影响符号表达式的可控性。在传统神经网络中，激活稀疏性通常由 ReLU 等非线性函数诱导 [23]，并可通过正则化或结构优化进一步增强 [4, 8, 18]。然而，在符号神经网络中，激活稀疏性不仅关系到计算效率，还会直接影响学习到的表达式能否稳定收敛到紧凑结构。特别是在 EQL 框架内，结构稀疏性和梯度稀疏性都有助于抑制冗余项，并维持紧凑、可解释的表达式。

为解决当前 EQL 模型中结构恢复不稳定和冗余激活的来源，我们提出 *EQL-Z*，一种新的训练机制，从算子设计和训练动态两个角度增强结构控制，以实现表达式简化和模型压缩这两个目标。

3 优化不稳定性的经验观察

我们首先形式化 EQL 网络的基本结构及其符号计算流程。随后，我们分析一个拟合目标公式的具体案例，重点关注网络的梯度响应以及其恢复理想解析结构的能力。

3.1 EQL 网络结构定义

设输入样本为 $x \in \mathbb{R}^d$ ，其中 d 表示输入变量的维度。一个 EQL 网络由 L 层组成，其中第 0 层为输入层，第 L 层为输出层，其余层为隐藏层；结构示意图见附录图 4。

在每个隐藏层中，网络首先对其输入施加线性变换。第 l 层的线性输出记为 $z^{(l)} \in \mathbb{R}^{m_l}$ ，计算方式为

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)},$$

其中 $W^{(l)} \in \mathbb{R}^{m_l \times n_{l-1}}$ 是第 l 层的权重矩阵， $b^{(l)} \in \mathbb{R}^{m_l}$ 是偏置向量， $a^{(l-1)} \in \mathbb{R}^{n_{l-1}}$ 是第 $(l-1)$ 层的激活输出。当 $l=1$ 时，初始激活为 $a^{(0)} = x$ 。

随后，网络将预定义的符号算子集合施加到线性输出 $z^{(l)}$ 上，得到激活输出 $a^{(l)}$ 。这些算子分为两类：**一元算子** $f_j: \mathbb{R} \rightarrow \mathbb{R}$ ，例如恒等函数 $\text{id}(z) = z$ 、正弦函数 $\sin(z)$ 和指数函数 $\exp(z)$ ；它们依赖单个输入变量，用于刻画基本非线性或周期行为。**二元算子** $g_k: \mathbb{R}^2 \rightarrow \mathbb{R}$ ，例如乘积算子 $g(x, y) = x \cdot y$ ，用于刻画成对输入之间的交互。

若当前隐藏层包含 u 个一元算子和 v 个二元算子，则线性输出维度需要满足 $m_l = u + 2v$ ，以提供所需输入。第 l 层的激活输出为

$$a^{(l)} = \left[f_1(z_1^{(l)}), \dots, f_u(z_u^{(l)}), g_1(z_{u+1}^{(l)}, z_{u+2}^{(l)}), \dots, g_v(z_{m_l-1}^{(l)}, z_{m_l}^{(l)}) \right]^\top,$$

其中前 u 个分量由一元变换得到，其余 v 个分量由成对二元运算产生。

输出层（第 L 层）不施加非线性符号算子，只执行线性组合以生成最终预测 $\hat{y} \in \mathbb{R}$ ：

$$\hat{y} = E(x) = W^{(L)} a^{(L-1)} + b^{(L)},$$

其中 $W^{(L)} \in \mathbb{R}^{1 \times n_{L-1}}$ ， $b^{(L)} \in \mathbb{R}$ 。

更一般地，整个网络的嵌套计算可写为

$$E(x) = W^{(L)} \cdot \Lambda^{(L-1)} \left(W^{(L-1)} \cdot \Lambda^{(L-2)} \left(\dots \right. \right. \\ \left. \left. \Lambda^{(1)} (W^{(1)} x + b^{(1)}) \dots + b^{(L-2)} \right) + b^{(L-1)} \right) + b^{(L)}.$$

其中每个 $\Lambda^{(l)}(\cdot)$ 表示第 l 层所有一元和二元符号算子的联合作用。

这一嵌套表达式突出了 EQL 网络的结构特征：通过多层线性映射和符号函数的组合，模型逐步构造出可解释的解析表达式。与传统神经网络相比，EQL 不仅近似函数值，还直接编码潜在函数结构，从而使显式公式恢复成为可能。

3.2 关键观察与动机

在一系列针对目标函数的受控实验中，我们观察到，即使 EQL 网络被初始化在一个与目标解析表达式高度匹配的“近乎最优”结构附近，训练仍会迅速激活冗余算子路径（如 $\exp$ ），并最




图 1: 训练过程中第 0、1 和 1000 个 epoch 的网络结构及对应梯度。

终收敛到包含冗余项的稳定解。当训练时间延长时，这种漂移现象往往更加明显。这些观察表明，在现有架构和训练机制下，目标解析结构并不总是稳定的局部极小值：冗余路径会持续接收非零梯度信号，从而破坏精确结构恢复。图 1 可视化了训练步骤 0、1 和 1000 时的网络结构与参数梯度，展示了冗余分支如何在早期被梯度“点燃”，并可能在接近收敛时仍保持活跃，而不是自然衰减为零。更多实验设置、拟合表达式和补充案例见附录 A。

4 方法

本节介绍 EQL-Z，一种用于 EQL 网络的结构可控训练框架。我们将 EQL 的冗余激活失败视为一个可从两条互补路径缓解的问题。第一条路径是在优化前减少冗余：在结构层面，我们采用由小到大的结构搜索，从紧凑种子网络开始，在显式复杂度控制下逐步增加宽度和深度，从而减少暴露给训练的不必要算子路径。第二条路径是让不可避免的冗余路径更容易静默：在算子层面，我们引入零点约束和零点一致变换，使冗余路径在输入和权重均为零时自然静默。当结构固定后，我们进一步采用基于 BFGS 的数值微调，以精确优化连续参数。

4.1 EQL 的零点约束

4.1.1 理论分析

在第 3 节中，我们观察到，即使 EQL 网络以非常接近目标表达式的结构初始化，训练仍会无意激活额外符号算子，并最终收敛到包含冗余项的局部最优。进一步的梯度分析表明，某些符号算子（如 $\exp$ ）即使输入为零也会输出非零常数（例如 $\exp(0) = 1$ ），因此在上游残差非零时，即使其前置系数为零，也会诱导非零梯度。这意味着，虽然某条路径上的连接权重被置零，该路径仍可能在训练中被激活和更新，从而破坏网络预期的稀疏模式。

在实践中，为控制模型复杂度并促进紧凑表示，通常会施加 ℓ_1 或 ℓ_0 正则化，以压缩冗余连接的权重。当连接权重 θ_j 接近零时，其输出项对整体损失的贡献减小，沿该路径反向传播的梯度也会变小。此外，由于该路径输入 z_j 通常是上一层输出的线性组合（例如 $z_j = \sum_k w_{jk} a_k^{(l-1)}$ ），一旦路径被有效关闭，相应的前向信号和反向梯度也会消失。这又会移除上游权重 w_{jk} 的更新信号，使其在正则化作用下进一步趋近于零。理想情况下，这一机制实现了路径层面的“结构静默”。

然而，如果算子本身在零输入处产生非零输出，那么即便权重归零，该路径仍可能接收非零梯度并继续被优化。这一机制解释了为什么 EQL 类模型中的冗余项难以被抑制。基于此，我们

提出在算子定义层面进行干预, 引入零点约束, 要求所有符号算子 $\Lambda(x)$ 满足 $\Lambda(0) = 0$ 。在连接权重和算子输入均为零的冗余路径条件下, 该约束使算子输出为零, 并移除由算子在原点处非零响应导致的残留梯度。

以输出层为例, 若某个连接的权重为 $\theta_j = 0$, 则模型输出关于该权重的导数为

$$\frac{\partial \hat{y}}{\partial \theta_j} = \Lambda_j(z_j).$$

若同时 $z_j = 0$ 但 $\Lambda_j(0) \neq 0$, 则该路径会把任何非零上游残差梯度转化为冗余连接上的非零更新。因此, 本应静默的连接会在训练中持续更新, 破坏学习表达式的稀疏性和稳定性。我们将这一现象形式化如下:

定义 4.1 (冗余算子路径). 在 EQL 网络中, 考虑一个表示为 $\theta_j \cdot \Lambda_j(z_j)$ 的连接, 其中 θ_j 是可训练参数, Λ_j 是符号算子, z_j 是其输入。若在最优解处 $\theta_j = 0$, 且该路径对输出没有实际贡献, 则称其为冗余算子路径。

定理 4.2 (冗余路径的非平稳性). 令 $\theta_j \cdot \Lambda_j(z_j)$ 为一条冗余路径。若 $\Lambda_j(0) \neq 0$, 则静默配置 $(\theta_j, z_j) = (0, 0)$ 在训练中通常不是平稳的, 除非上游损失梯度消失。

反过来, 当所有算子都满足零点约束 $\Lambda(0) = 0$ 时, 网络在冗余路径条件下获得自然的结构压缩性质: 只要某个连接具有零权重且零输入, 其路径相对于这一残留梯度通道就是静默的。这不仅增强了稀疏性, 也提高了最终表达式的可解释性。上述分析表明, 零点约束并非微小的设计细节, 而是改善此类失败模式下训练稳定性和模型压缩的重要机制。完整数学推导见附录 B。

4.1.2 零点一致变换

零点约束要求每个符号函数 $\Lambda(x)$ 满足 $\Lambda(0) = 0$, 以避免在权重和输入均为零时冗余连接上出现非零梯度 (见定理 4.2)。然而, 标准符号库中的许多常用算子并不天然满足这一条件, 例如 $\exp(0) = 1$, $\cos(0) = 1$, 而 $\log(x)$ 在 $x = 0$ 处甚至无定义。因此, 在构造算子集合时, 我们需要对这些函数进行结构变换, 使其呈现一致的零点行为。

我们将这一过程称为**零点一致变换**。其目标是在 $x = 0$ 的邻域内强制满足 $\Lambda(0) = 0$, 同时不显著削弱算子的表达能力。根据函数性质, 我们考虑两类变换: **输出平移**, 构造 $\Lambda(x) = f(x) - f(0)$, 适用于在 $x = 0$ 处定义良好的函数, 如 $\exp$ 、 $\cos$ 和幂函数; **输入平移**, 构造 $\Lambda(x) = f(x + \delta)$, 适用于原函数在 $x = 0$ 处无定义或不理想的情形, 如 $\log(x)$ 。

这些变换不会系统性降低常见目标函数的可达性, 但可能改变恢复公式的最小参数化形式。例如, 目标项 $a \exp(bx) + c$ 可由变换后的算子表示为 $a(\exp(bx) - 1) + (a + c)$, 其中常数项吸收了输出平移。因此, 零点变换可能在原始导出表达式中引入偏置项, 我们会在符号提取后对其进行简化。

实践中, 我们建议在设计符号网络架构时优先采用输出平移, 因为它在保持梯度传播结构的同时强制原点处零响应, 使冗余连接能够自然衰减。对于无法通过输出平移处理的算子 (例如 $\log(x)$), 我们采用输入平移使定义域远离零。对于除法等奇异算子, 我们沿用 EQL $\div$ [27] 中的正则化除法: 给定阈值 $\theta > 0$,

$$h^\theta(a, b) = \begin{cases} a/b, & b > \theta, \\ 0, & \text{otherwise,} \end{cases} \quad p^\theta(b) = \max(\theta - b, 0).$$

这里 h^θ 在禁止的小分母区域同时将输出和相应梯度置零，而 p^θ 惩罚这类分母并引导网络远离它们。这种处理与我们的静默路径稳定性观点一致，尽管针对所有奇异算子的统一理论仍是重要扩展方向。总体而言，这些变换作为独立于训练过程的结构预处理步骤，系统性增强了稀疏性和可解释性。常见符号算子的零点一致变换总结见附录 B.3。

4.2 由小到大的结构搜索

零点约束使候选结构中出现的冗余路径更容易静默，而另一条互补路径是在一开始就减少暴露给优化的冗余路径数量。为此，我们提出由小到大的结构搜索策略：从用户指定或启发式选择的紧凑初始架构 $\mathcal{L}_0$ 出发，通过局部修改逐步扩展网络宽度和深度，同时显式控制搜索复杂度并保持表达能力。这一结构层面的路径不同于先训练大型网络再事后剪枝：它把冗余减少作为搜索过程本身的一部分，因此只有当新算子能够改善带复杂度惩罚的验证分数时才会被引入。

结构表示与阶段控制 具体而言，我们将 EQL 架构表示为跨层算子集合列表：

$$\mathcal{L} = \{\mathcal{O}^{(1)}, \dots, \mathcal{O}^{(L)}\}, \quad \mathcal{O}^{(l)} = \{o_1^{(l)}, \dots, o_{m_l}^{(l)}\},$$

并在预定义的层数范围 $[L_{\min}, L_{\max}]$ 与每层算子上限 $m_l \leq m_{\max}$ 内搜索。所有算子按照功能角色或复杂度分组为 $\{\mathcal{F}_1, \dots, \mathcal{F}_S\}$ ，例如多项式、三角函数、对数/有理函数等。在实现中，我们引入阶段变量 s 控制算子逐步开放：在阶段 s ，局部增长从 $\bigcup_{i \leq s} \mathcal{F}_i$ 中采样算子，而更高层级算子及其相关候选结构在后续阶段打开前保持非活跃。阶段 s 根据验证性能增益和搜索进展的启发式规则增加，例如当若干步内性能提升变得边际时逐步解锁更高层级算子族，从而防止复杂算子过早引入。

局部增长与复杂度惩罚评分 在每一步 t ，算法围绕当前结构 $\mathcal{L}_t$ 构建紧凑候选池，局部增长通过两类编辑作为主要机制：(i) **增宽 (AddOp)**。对已有层 ℓ ，从当前阶段允许的算子族中采样一个算子，并在该层未达到上限 $m_{\max}$ 时将其加入 $\mathcal{O}_t^{(\ell)}$ ；(ii) **加深 (AddLayer)**。当 $L_t < L_{\max}$ 时，在输出侧追加新层，通常以少量新采样算子初始化。实现中，候选池还可通过有界邻域编辑轻量扩充，例如受限算子替换或小型层模板；同一层内算子排列导致的等价结构会被规范化并去重。因此，搜索轨迹仍以很小步长穿过结构空间，避免在巨大候选集上进行大跳跃。

为在精度与复杂度之间实现可控权衡，我们为每个结构 $\mathcal{L}$ 定义复杂度惩罚分数：

$$S(\mathcal{L}) = R_{\text{val}}^2(\mathcal{L}) - \lambda_{\text{comp}} \cdot \frac{\text{Comp}(\mathcal{L})}{C_{\max}},$$

其中 R_{val}^2 表示验证集上的决定系数， $\text{Comp}(\mathcal{L})$ 是符号树大小或算子数量， $C_{\max}$ 设置为当前搜索预算下允许的最大结构复杂度，使复杂度惩罚在候选架构之间归一化。对于每个被评估的候选结构，我们在相应结构上训练 EQL 模型（使用零点一致算子和标准梯度优化器），得到 R_{val}^2 及对应的复杂度惩罚分数 $S(\mathcal{L}_{\text{new}})$ ，并与历史最佳分数 S^* 比较。仅当分数至少提高一个小阈值 δ_{score} 时，才接受结构更新。对于增加深度的候选，我们额外要求验证增益 ΔR^2 超过预设阈值 $\varepsilon_{\text{layer}}$ ，以防止无效加深。

族自适应采样与早停 算子族采样由一组可学习权重 $\{w_i\}$ 控制。我们将一步性能改进 ΔR^2 视为当前选中算子族的局部奖励，并通过指数加权移动平均更新 w_i 。随后应用带温度缩放和下界裁剪

的 softmax 得到族级采样概率 $\{\pi_i\}$ 。这样，历史上带来更大性能提升的算子族在后续步骤中更可能被采样，从而逐渐将结构搜索聚焦到“有效算子子空间”。

当满足以下任一条件时，整体搜索提前终止：达到最大步数，分数连续 K_{stop} 步没有显著提升，或 R^2 超过预设阈值。最终输出是在复杂度与精度之间取得最佳权衡的结构。完整流程见附录 C。

4.3 基于 BFGS 的数值微调

一旦由小到大的结构搜索确定最终符号架构 $\mathcal{L}_{\text{best}}$ ，模型中剩余的不确定性主要来自连续参数的数值精度。因此，我们在固定结构下对这些系数执行额外且独立的数值微调，以进一步提高拟合精度。

具体而言，我们首先从 EQL 网络中提取与 $\mathcal{L}_{\text{best}}$ 对应的解析表达式，并收集表达式中出现的连续参数，包括仿射权重、偏置以及由符号路径引入的标量系数，形成参数向量 $\theta \in \mathbb{R}^d$ 。给定训练数据 (X, Y) （可选地加入部分验证数据），我们定义均方误差损失

$$\mathcal{L}_{\text{MSE}}(\theta) = \frac{1}{N} \sum_{n=1}^N (f_{\mathcal{L}_{\text{best}}}(x_n; \theta) - y_n)^2,$$

其中 $f_{\mathcal{L}_{\text{best}}}$ 表示结构固定的符号网络。随后，我们使用 BFGS 在连续参数空间中最小化 $\mathcal{L}_{\text{MSE}}$ 。BFGS 是一种二阶拟牛顿方法，利用局部 Hessian 近似更准确地捕捉参数变化对损失的二阶影响，从而在较少迭代中获得高精度系数估计。

实现中，BFGS 优化直接作用于提取出的解析表达式，而不是重新进入完整神经网络训练循环：每次迭代只涉及表达式前向求值、关于 θ 的梯度反向计算，以及按 BFGS 规则进行参数更新。这一过程等价于在固定符号形式下对系数进行“最后一公里”的数值精修，使模型输出更接近目标函数的真实系数和常数项。在实验中，该步骤通常在不改变结构的前提下明显提升 R^2 ，并减少一阶优化器引入的轻微偏差。

5 实验

本节系统评估所提方法的有效性、稳定性和结构紧凑性。实验围绕以下研究问题 (RQ) 组织，旨在评估 EQL-Z 在函数恢复任务上的表现，并理解其关键组件的贡献：

RQ1. 在标准基准数据集上，相比现有符号回归方法，EQL-Z 是否能在预测精度与模型可解释性（如表达式复杂度）之间取得更好权衡？

RQ2. 除理论分析外，所提出的零点约束是否能在实践中有效抑制冗余算子并改善训练稳定性？

RQ3. EQL-Z 在多大程度上提升精确方程恢复率？

RQ4. 在分布偏移和观测噪声下，EQL-Z 的泛化与外推能力如何？

RQ5. EQL-Z 在真实世界记忆数据集上表现如何？为回答 RQ5，我们基于 MaiMemo 数据集加入了一个人类记忆建模辅助实验。详细设置和符号表达式见附录 G。

5.1 实验与评估设置

我们在三类数据集上评估 EQL-Z：合成 Nguyen 基准函数 [32]、SRBench [12]，以及覆盖三个科学领域的新基准问题 [?]。Nguyen 基准用于在受控噪声下评估精确方程恢复；SRBench 包含




图 2: 黑盒数据集上的性能与复杂度比较, 包括不同噪声水平下的 R^2 、基于容差的准确率和表达式长度。每个子图按四个噪声水平上的平均 R^2 对算法排序, 点表示平均结果, 误差条表示跨子任务的性能方差。




图 3: 对算子施加零点校正后, 目标 $(x_1 + x_2)^2$ 的网络与梯度信息。

既有已知解析真值的数据集, 也有纯黑盒回归问题, 我们用其在紧计算预算下评估 EQL-Z 的限时性能; 科学基准包含非线性动力学、微生物学和材料科学中的四个 LLM-SR 问题 (Oscillation 1、Oscillation 2、*E. coli* growth 和 Stress-Strain), 共同测试真实物理系统上的 ID/OOD 泛化。我们考虑三个高斯噪声水平, 其标准差为 $\sigma = 0.1, 0.01, 0.001$ 。按照 [13] 中的范围设定, 我们生成 12 个 Nguyen 函数, 每个函数包含 1000 个训练点。更多细节见附录 E。除非另有说明, EQL-Z 在完整算子库 {id, square, cube, sin, cos_reg, mul, add, sqrt_reg, exp_reg, log_reg, pow_reg, div_reg} 上搜索, 其中包含保护除法, 而不是定制的仅平滑算子子集。作为对除法的额外压力测试, EQL-Z 在包含除法的 Feynman-I-18-4 公式上达到 100% 精确恢复, 而 Feynman-I-39-22 由于同时具有除法和乘法分子结构仍较具挑战性。

5.2 RQ1: 性能比较

图 2 从不同噪声水平下的预测精度、基于容差的准确率和表达式长度等方面, 将 EQL-Z 与多个 SRBench 黑盒数据集基线进行比较。如图所示, 虽然 EQL-Z 略落后于部分先进的 GP 类方法, 但它保持了复杂度更低、结构更紧凑的模型。与原始 EQL 相比, EQL-Z 在整体性能上持续更优, 并恢复出显著更简单的模型; 其优势在细粒度指标 (如逐样本误差) 上尤为明显, 在该基准上将平均模型复杂度降低超过 80%。此外, EQL-Z 对噪声更鲁棒, 在所有噪声水平下均优于原始 EQL, 尤其在低噪声设置中提升更为显著。带真实公式的数据集结果见附录 F。

表 1: 12 个标准 Nguyen 基准上的精确方程恢复率。EQL 家族结果为 20 次独立运行的平均值。带 † 的列来自已有工作 [?]; 完整组件级消融见附录 F。

Benchmark	Expression	EQL-Z	EQL	ParFam [†]	SPL [†]	NGGP [†]	GP [†]
Nguyen-1	$x^3 + x^2 + x$	100%	0%	100%	100%	100%	99%
Nguyen-2	$x^4 + x^3 + x^2 + x$	100%	0%	100%	100%	100%	90%
Nguyen-3	$x^5 + x^4 + x^3 + x^2 + x$	100%	0%	100%	100%	100%	34%
Nguyen-4	$x^6 + x^5 + x^4 + x^3 + x^2 + x$	100%	0%	100%	99%	100%	54%
Nguyen-5	$\sin(x^2) \cos(x) - 1$	80%	0%	83%	95%	80%	12%
Nguyen-6	$\sin(x) + \sin(x^2 + x)$	100%	0%	83%	100%	100%	11%
Nguyen-7	$\log(x + 1) + \log(x^2 + 1)$	100%	0%	100%	100%	100%	17%
Nguyen-8	$\sqrt{x}$	100%	0%	100%	100%	100%	100%
Nguyen-9	$\sin(x_0) + \sin(x_1^2)$	100%	0%	100%	100%	100%	76%
Nguyen-10	$2 \sin(x_0) \cos(x_1)$	100%	0%	100%	100%	100%	86%
Nguyen-11	x^y	100%	0%	0%	100%	100%	13%
Nguyen-12	$x_0^4 - x_0^3 + 0.5x_1^2 - x_1$	100%	0%	100%	28%	4%	0%
Average		98.3%	0.0%	88.8%	93.5%	90.3%	49.3%

5.3 RQ2: 零点约束的有效性

为验证零点约束是否抑制不必要的算子激活，我们进行受控比较并跟踪每个算子早期阶段的梯度响应（图 3）。我们将未使用零点一致变换、剪枝或 BFGS 微调的原始 EQL 架构作为基线。目标为 $\text{eq} = (x_1 + x_2)^2$ ，其中 $x_1, x_2 \sim U(-1, 1)$ ，高斯噪声 $\epsilon \sim \mathcal{N}(0, 0.01^2)$: $\text{target} = (x_1 + x_2)^2 + \epsilon$ 。我们采样 100 个点，并使用学习率 0.1、 L_1 正则化系数 0.01 训练 EQL 20,000 步。在相同初始化下，我们比较有无零点约束 ($\Lambda(0) = 0$) 的训练过程。

在 epoch 0 时，梯度几乎相同；由于噪声，平方算子在两种设置下都表现出弱响应。在 epoch 1 时，没有约束的情况下， $\exp$ 算子的梯度迅速增大（峰值 > 0.6 ），表明其被错误激活。相比之下，有约束时， $\exp$ 梯度在整个训练过程中始终为零，即使在早期阶段也是如此。这支持了我们的主张：强制 $\Lambda(0) = 0$ 能阻断无效梯度路径，并防止冗余算子被错误激活。

5.4 RQ3: 方程恢复实验

我们在 Nguyen 基准上评估不同方法的精确方程恢复能力，并对零点约束和由小到大结构搜索进行消融研究。对于 EQL 家族方法（原始 EQL 与我们的 EQL-Z 变体），结果是在不同随机种子下 20 次独立运行的平均值；其他基线直接取自 ParFam 论文 [?]。表 1 报告了 12 个标准 Nguyen 函数上的方程恢复率，完整的组件级 20 次运行消融见附录 F（表 6）。我们观察到，EQL-Z 在 12 个基准中的 11 个上达到 100% 恢复率，并在最具挑战性的 Nguyen-5 上达到 80%，平均恢复率为 98.3%，显著高于相同协议下原始 EQL 的 0.0%。

附录 F 的消融结果显示，移除零点约束（EQL-Z_{w/o} ZP）会使平均恢复率降至 86.3%；若进一步舍弃由小到大的策略，改用单个大型固定架构（EQL-Z_{w/o} STL），多个函数上的恢复率会降至 0%，平均恢复率仅为 17.9%。总体而言，EQL-Z 的恢复性能与 ParFam (88.8%) 和 SPL (93.5%) 等强基线相当；结合附录表 5 和表 6 可见，零点一致算子、由小到大结构搜索和数值精修在方程恢复中发挥互补作用。更具体地说，由小到大策略通过降低干扰算子进入候选架构的机会，提供

表 2: 真实世界任务上的泛化性能 (ID/OOD NMSE; 越低越好)。带 † 的行来自已有工作 [?].

Model	Oscillation 1		Oscillation 2		<i>E. coli</i> growth		Stress-strain	
	ID ↓	OOD ↓	ID ↓	OOD ↓	ID ↓	OOD ↓	ID ↓	OOD ↓
GPlearn [†]	0.0155	0.5567	0.7551	3.1880	1.0810	1.0390	0.1063	0.4091
NeSymReS [†]	0.0047	0.5377	0.2488	0.6472	N/A ($d \leq 3$)	N/A ($d \leq 3$)	0.7928	0.6377
E2E [†]	0.0082	0.3722	0.1401	0.1911	0.6321	1.4467	0.2262	0.5867
DSR [†]	0.0087	0.2454	0.0580	0.1945	0.9451	2.4291	0.3326	1.1080
uDSR [†]	<u>0.0003</u>	<u>0.0007</u>	0.0032	<u>0.0015</u>	0.3322	5.4584	0.0502	0.1761
PySR [†]	0.0009	0.3106	<u>0.0002</u>	0.0098	<u>0.0376</u>	<u>1.0141</u>	<u>0.0331</u>	<u>0.1304</u>
EQL	2.5078	2.3894	0.6686	1.6729	0.9709	1.0022	0.3377	1.0349
EQL-Z	0.0032	0.0087	0.0057	0.0036	0.8405	0.9253	0.0346	0.1597
LLM-SR (Mixtral) [†]	7.89e-8	0.0002	0.0030	0.0291	0.0026	0.0037	0.0162	0.0946
LLM-SR (GPT-3.5) [†]	4.65e-7	0.0005	2.12e-7	3.81e-5	0.0214	0.0264	0.0210	0.0516

主要结构收益；而当冗余算子仍存在于结构中时，零点约束提升优化鲁棒性。BFGS 则承担不同角色：它主要在有希望的符号形式已经找到后精修数值系数，而不是执行结构发现。这种组件级行为支持了我们的观点：EQL-Z 通过结构层面的搜索控制和算子层面的梯度稳定共同改善恢复能力。

5.5 RQ4: 泛化实验

表 2 显示，在四个真实世界任务上，LLM-SR 取得了整体最低 ID 和 OOD 误差。在不使用语言先验的方法中，EQL-Z 保持竞争力，同时相较原始 EQL 有显著提升，ID/OOD NMSE 往往降低一个或多个数量级。

6 结论

我们提出了 EQL-Z，一种结构可控的神经符号回归框架，它通过零点约束算子、由小到大的结构搜索，以及在提取解析表达式上的 BFGS 微调，针对残留梯度机制改善了 EQL 训练稳定性。在合成、黑盒、物理和真实世界行为任务上的实验表明，相比原始 EQL，EQL-Z 提升了方程恢复能力和表达式紧凑性，同时与领先符号回归基线保持竞争力。未来工作包括扩展算子库，并将 EQL-Z 与自动架构搜索结合，以处理更丰富的算子集合和更复杂的符号空间。

致谢

本工作得到国家自然科学基金(62437002, 62577028, 62293554)、湖北省自然科学基金(2023AFA020)以及中央高校基本科研业务费专项资金(JC2026TS-014, XJ2026001102, XJ2026003301)的资助。

影响声明

本工作旨在通过提高 EQL 类方法的稳定性和可控性，推动符号回归与可解释建模领域的发展。我们预期其社会影响在性质上类似于现有用于科学发现和数据分析的机器学习工具；除关于数据质量、偏差和误用的常规担忧外，我们未发现任何直接且特定于应用领域的风险。

A 实验案例

A.1 网络示意图




图 4: EQL 网络。该图展示了一个 3 层 EQL 网络，其中每个隐藏层包含三个算子：两个一元算子和一个二元算子 ($u = 2, v = 1$)。实线表示目标方程 $y = x_2 \sin(x_1)$ 。




图 5: 目标函数 $\sin(x_2)$ 训练过程中的网络结构和对应梯度。






图 6: 施加算子校正后, $\sin(x_2)$ 训练过程中的网络结构和对应梯度。

图 7: 目标函数 $x_1 + 2x_2$ 训练过程中的网络结构和对应梯度。图 8: 施加算子校正后, $x_1 + 2x_2$ 训练过程中的网络结构和对应梯度。

A.2 实验设置

我们首先考虑一个简单玩具问题, 其真实目标公式为 $\text{eq} = (x_1 + x_2)^2$ 。我们从均匀分布 $U(-1, 1)$ 中独立采样 x_1 和 x_2 , 共生成 100 个数据点。目标值中加入标准差为 0.01 的高斯噪声:

$$x_1, x_2 \sim U(-1, 1), \quad \epsilon \sim \mathcal{N}(0, 0.01^2),$$

$$\text{target} = (x_1 + x_2)^2 + \epsilon.$$

EQL 网络的目标是将该公式表示为神经架构, 并通过逐层符号算子组合渐近逼近它。训练过程中, 网络调整参数以从带噪观测中恢复潜在解析结构。

在 ℓ_1 正则化系数 $\lambda_{L_1} = 0.01$ 下, 我们使用单隐藏层 EQL 架构, 其算子集合为 $[\text{square}, \text{exp}]$ 。尽管目标表达式很简单, 且网络具有足够表示能力, 模型仍未能恢复期望结构。对于该算子配置, 最终拟合表达式为

$$\hat{y} = 0.192 + 0.094 \cdot \exp(-1.882x_1) \exp(-2.042x_2).$$

显然, 模型没有重构二次结构 $(x_1 + x_2)^2$, 而是集中到一条指数路径表示上。这表明, 即使架构和超参数与目标较为匹配, EQL 也可能收敛到错误解, 并难以重构预期解析形式。我们推测, 该失败源于优化轨迹没有朝向最简单兼容结构前进。

为进一步探查该问题, 我们设计了一个极端但有启发性的实验: 将网络初始化为几乎等同于

目标公式

$$1.0 \cdot (1.0x_1 + 1.0x_2)^2,$$

并将所有偏置项和指数相关参数置零，以消除不必要算子的干扰。虽然这种初始化在实际应用中几乎不可能获得，但原则上它应提供理想的优化起点。

从经验角度看，当模型被初始化到非常接近目标解析结构的位置时，我们期望其迅速收敛到理想解。在实验中，模型在 1000 个 epoch 内触发早停，最终拟合表达式（保留三位小数）为

$$\begin{aligned} \hat{y} = & 0.979 \cdot (0.995x_1 + x_2 + 0.004)^2 \\ & + 0.006 \cdot \exp(-0.004x_1 + 0.014x_2). \end{aligned}$$

指数项的激活表明网络仍引入了冗余结构。更重要的是，当我们关闭早停并继续训练更久时，模型偏离目标结构的程度变得更加明显。这说明，即便从近最优配置出发，EQL 也容易在训练中被引向非解析路径，暴露出固有的结构不稳定性。

A.3 梯度分析

为分析优化早期和后期的梯度行为，我们记录了 epoch 0、1 和 1000 时的参数梯度（见图 1）。从已经接近理论最优的初始化出发，我们观察到梯度演化中的两个关键现象：

1. **冗余项在早期迅速被激活。** 尽管 $\exp$ 项的系数初始化为零，其梯度在仅一次更新后就变为非零，说明网络立即对这些冗余算子产生响应。若干步后，这些梯度进一步放大（例如在 `layer_0` 中达到约 -0.67 的量级），表明模型快速偏离紧凑结构并转向更复杂表达式。
2. **网络收敛到包含冗余项的局部最优。** 到 epoch 1000 时，所有梯度都降到 10^{-4} 量级以下，说明模型接近收敛。然而，输出仍包含不可忽略的指数项，这意味着网络并未收敛到与目标解析表达式对应的最优结构，而是稳定在含冗余成分的局部极小值。换言之，即使从理论解附近出发，当前 EQL 网络仍容易陷入错误的过参数化最优。

我们还在另外两个目标公式 $\sin(x_2)$ 和 $x_1 + 2x_2$ 上进行了受控实验（见附录 A），并得到定性相似的结果：即使初始化非常接近目标表达式，冗余算子仍会在训练中被激活，并且不会自然衰减到零。这些观察指出了一个核心问题：在当前架构和训练机制下，真实解析公式并不对应稳定的局部极小值。即使从理论最优附近开始，冗余算子也会被激活并在一段时间内保持显著梯度，最终使网络收敛到包含多余项的局部最优。

B 定理 4.2 的证明

本节给出定理 4.2 的形式化证明，说明如果冗余路径上的符号算子 Λ_j 不满足零点一致条件（即 $\Lambda_j(0) \neq 0$ ），则静默配置 $(\theta_j, z_j) = (0, 0)$ 在训练中通常不是平稳的，除非上游损失梯度消失。

实践中，为控制模型复杂度并鼓励紧凑表达式，通常引入 ℓ_1 或 ℓ_0 稀疏正则化，以驱动冗余连接权重 θ_j 趋近于零。一旦路径被压缩（即 $\theta_j \rightarrow 0$ ），其输出项 $\theta_j \cdot \Lambda_j(z_j)$ 对整体误差的贡献可忽略。此外，正则化效应会向后传播：由于 z_j 通常是上一层激活的加权和，例如 $z_j = \sum_k w_{jk} a_k^{(l-1)}$ ，且该路径不再被使用，该项对损失的梯度贡献也会消失。因此，与该路径相连的上游权重 w_{jk} 也会在稀疏正则化下趋近于零。

换言之，一旦某个连接变为冗余且其输出被有效剪除，对应反向传播链上的梯度会趋近于零，使上游权重失去更新信号。这进一步导致 $z_j \rightarrow 0$ ，形成路径层面的结构静默。

然而，该静默机制关键依赖 Λ_j 在零点处的行为。若 $\Lambda_j(0) \neq 0$ ，那么即便 $\theta_j = 0$ 且 $z_j = 0$ ，梯度

$$\frac{\partial L_{\text{total}}}{\partial \theta_j} = \Lambda_j(0) \cdot \frac{\partial L_{\text{total}}}{\partial \hat{y}}$$

在上游损失梯度非零时仍为非零，从而破坏该路径预期的衰减，并诱导不必要的参数扰动和表达式误差。

因此，我们在算子层面引入**零点一致约束**，要求所有符号算子满足

$$\Lambda(0) = 0.$$

在冗余连接同时具有零权重和零输入的条件下，零点一致性使算子输出为零，并移除该路径上的残留梯度通道。因此，冗余连接能够更容易保持静默并被剪除，从而增强网络稀疏性和学习表达式的可控性。

B.1 非零梯度分析

考虑网络中单条路径的贡献：

$$y_j = \theta_j \cdot \Lambda_j(z_j),$$

其中 θ_j 是可训练参数， $\Lambda_j(z_j)$ 是符号算子作用于输入后的输出。在点 $(\theta_j, z_j) = (0, 0)$ 处，有

$$y_j = 0.$$

假设总损失 L_{total} 依赖模型输出 $\hat{y} = \sum_j y_j$ ，并且关于 θ_j 可微。则在该点处，损失关于 θ_j 的偏导数为

$$\frac{\partial L_{\text{total}}}{\partial \theta_j} = \frac{\partial L_{\text{total}}}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial \theta_j} = \frac{\partial L_{\text{total}}}{\partial \hat{y}} \cdot \Lambda_j(0).$$

由于训练过程中通常有 $\frac{\partial L_{\text{total}}}{\partial \hat{y}} \neq 0$ （除非输出已经完美拟合目标），当 $\Lambda_j(0) \neq 0$ 时可得

$$\frac{\partial L_{\text{total}}}{\partial \theta_j} \neq 0.$$

因此，在非零上游损失梯度下，点 $(\theta_j, z_j) = (0, 0)$ 不满足平稳点的零梯度条件，定理得证。□

B.2 剪枝中零点一致性的必要性

这一结果突出了剪枝中的一个关键方面：如果被剪除路径上的符号算子在零输入处产生非零输出，那么即使路径权重被置零，它仍会在优化过程中诱导非零梯度，因此无法在训练中自然保持静默。为确保剪枝后的优化景观保持稳定，需要被移除路径满足

$$\Lambda_j(0) = 0.$$

因此，冗余路径的静默不仅依赖于将权重压到零，也关键依赖于算子自身的零点行为。

B.3 补充说明：算子设计准则

表 3 总结了 EQL-Z 中对常见符号算子施加的零点一致变换。

表 3: 符号算子的零点一致变换。

原始算子	$\Lambda_{\text{raw}}(0)$	变换后 $\Lambda(x)$	$\Lambda(0)$	处理类型
$\text{id}(x)$	0	x	0	天然满足
$\text{square}(x)$	0	x^2	0	天然满足
$\text{cube}(x)$	0	x^3	0	天然满足
$\sin(x)$	0	$\sin(x)$	0	天然满足
$\cos(x)$	1	$\cos(x) - 1$	0	输出平移
$\exp(x)$	1	$\exp(x) - 1$	0	输出平移
$\log(x)$	$-\infty$	$\log(x + 1)$	0	输入平移
$\text{mul}(x, y)$	0	$x \cdot y$	0	天然满足
$\text{add}(x, y)$	0	$x + y$	0	天然满足
$\text{pow}(x, y)$	1	$\text{pow}(x, y) - 1$	0	输出平移
$\text{div}(x, y)$	未定义	$\begin{cases} x/y, & y > \theta \\ 0, & \text{otherwise} \end{cases}$	0	正则化除法

C 由小到大的结构搜索

算法 1 概述了 EQL-Z 中用于增长紧凑架构的由小到大结构搜索流程。

D 局限性与未来工作

由小到大的结构搜索会引入额外计算成本，并依赖种子结构、增长规则和复杂度惩罚评分等启发式选择。因此，它在更高输入维度或显著更复杂算子库上的可扩展性仍是未来工作的重要方向。此外，尽管 EQL-Z 在真实世界科学任务上相比原始 EQL 有显著提升，但仍落后于 LLM-SR，这表明将 EQL 式连续优化与更强结构先验相结合是一个有前景的方向。

E 实验与评估设置

E.1 指标与基线

我们围绕论文中的主要研究问题 (RQ) 组织评估指标，并遵循符号回归和外推评估中的既有实验协议。

RQ1 的指标: 预测性能与模型紧凑性 对于 **RQ1** (整体预测性能与模型紧凑性)，我们遵循 [3, 9] 的实验指南，采用三个指标: 决定系数 R^2 、基于容差的准确率 ACC_ω 和表达式复杂度 $Complexity$ 。 R^2 衡量预测值 $\tilde{y}_i$ 与真实值 y_i 之间的拟合优度:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \tilde{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

其中 $\bar{y}$ 是目标 y_i 的均值。基于容差的准确率 ACC_ω 定义为相对误差不超过阈值 ω 的样本比例:

$$\frac{|y_i - \tilde{y}_i|}{|y_i|} \leq \omega.$$

Algorithm 1: 由小到大的结构搜索

Input: 训练/验证数据 (X, Y) ; 算子族 $\{\mathcal{F}_1, \dots, \mathcal{F}_S\}$; 初始结构 $\mathcal{L}_0$; 超参数 Θ (深度/宽度限制、步数预算、阶段设置、早停阈值等)。

Output: 选定结构 $\mathcal{L}_{\text{best}}$ 及其对应解析表达式。

设置当前结构 $\mathcal{L} \leftarrow \mathcal{L}_0$;

在 $\mathcal{L}$ 上训练 EQL (使用零点一致算子), 得到 R_{curr}^2 和分数 $S(\mathcal{L})$;

令 $S^* \leftarrow S(\mathcal{L})$, $\mathcal{L}_{\text{best}} \leftarrow \mathcal{L}$;

初始化族权重 w 、阶段 $s \leftarrow 1$ 、计数器和 $t \leftarrow 0$;

repeat

$t \leftarrow t + 1$;

 根据 w 计算当前阶段的采样概率 π ;

 按 π 采样族索引 i , 再采样算子 $o^* \in \mathcal{F}_i$;

 使用局部增长 (ADDOP/ADDLAYER) 围绕 $\mathcal{L}$ 构造候选结构;

 可选地加入有界邻域候选, 然后选择一个候选结构 $\mathcal{L}_{\text{new}}$ 评估;

 在 $\mathcal{L}_{\text{new}}$ 上训练 EQL, 得到 R_{new}^2 和分数 S_{new} ;

 计算 $\Delta R^2 \leftarrow R_{\text{new}}^2 - R_{\text{curr}}^2$;

if 执行加深且 $\Delta R^2 < \varepsilon_{\text{layer}}$ **then**

 拒绝该增长, 保持 $\mathcal{L}$;

else

if $S_{\text{new}} \geq S^* + \delta_{\text{score}}$ **then**

 接受候选: 更新 $\mathcal{L} \leftarrow \mathcal{L}_{\text{new}}$, $R_{\text{curr}}^2 \leftarrow R_{\text{new}}^2$;

 更新 $S^* \leftarrow S_{\text{new}}$, $\mathcal{L}_{\text{best}} \leftarrow \mathcal{L}$;

 使用 ΔR^2 更新族权重 w_i ;

 更新阶段/全局停滞计数器; 若满足阶段解锁条件, 则令 $s \leftarrow s + 1$;

until $t \geq T_{\text{max}}$ 或触发早停或 $R_{\text{curr}}^2 \geq R_{\text{max}}^2$;

return $\mathcal{L}_{\text{best}}$ 及其对应解析表达式;

表达式复杂度 *Complexity* 使用公式长度衡量, 即恢复表达式中符号和参数的总数, 遵循 [3, 9]。

RQ3 的指标: 精确方程恢复率 对于 RQ3 (精确方程恢复能力), 我们采用近期可控 SR 工作 [?] 中的恢复率协议。方程恢复率定义为恢复表达式与真实目标代数等价的运行比例。具体而言, 若恢复表达式在化简后 (例如通过展开、因式分解或对数恒等式) 与目标代数等价, 即便其表面语法形式不同, 也视为成功。例如,

$$\log(x^3 + x^2 + x^2 + x + 1) \quad \text{and} \quad \log(x^2 + 1) + \log(x + 1)$$

经代数化简后被视为等价, 均计为 “正确恢复”。所有恢复率均在多个随机种子、初始结构和初始化方案上取平均。

RQ4 的指标: 分布偏移下的泛化 对于 RQ4 (分布偏移和外推下的泛化), 我们遵循基于 LLM 的符号回归 [?] 中的 ID/OOD 评估协议, 并以归一化均方误差 (NMSE) 作为主要指标。给定预

表 4: 本研究评估的 SR 方法及其分类。*Gen* 表示生成式 SR; *RL*、*GS* 和 *GP* 分别表示探索式 SR 中的强化学习、网格搜索和遗传编程。

Method	Class	Description
TPSR-E2E	Gen	预训练 SR 模型的改进 MCTS 式优化器
E2E	Gen	用于直接公式预测的预训练模型
DSR	RL	基于 RNN 的强化学习 SR
AlFeynman	GS	用于发现物理方程的增强工具包
BSR	GS	贝叶斯符号回归
FFX	GS	快速函数提取
EQL	GS	以符号算子作为激活的 MLP
OccamNet	GS	采用随机算子路径选择的稀疏神经符号模型
DYSYMNET	GS	采用 RL 驱动结构优化的 EQL 式模型
eEQL	GS	具有渐进结构演化的进化方程学习器
AFP	GP	年龄-适应度 Pareto 优化
AFP_FE	GP	带共同演化适应度估计的 AFP
EPLEX	GP	ϵ -lexicase 选择
GP-GOMEA	GP	采用基因池最优混合进化算法的 GP
SBP-GP	GP	语义反向传播 GP

测值 $\tilde{y}_i$ 与真实值 y_i , NMSE 定义为

$$\text{NMSE} = \frac{\sum_{i=1}^n (y_i - \tilde{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

其中分母用目标方差对 MSE 进行归一化, 使不同数据集上的误差可比较。

基线方法 为保证比较全面, 我们从 GP、RL、EQL 式方法和生成式 SR 等不同家族中选择代表性或最先进方法, 共 15 个基线。这些方法及其分类见表 4。

E.2 更多实验细节

(1) 训练配置与计算预算 对于所有 EQL 家族方法, 我们采用统一训练配置, 而不是为每个 Nguyen 函数分别调参。除非另有说明, 学习率设为 0.01, L_1 正则化系数设为 0.01, 每个候选模型训练 10,000 个 epoch。在由小到大的结构搜索中, 我们设置 $L_{\text{start}} = 1, L_{\text{max}} = 2, \text{max_ops_per_layer} = 3, \text{operator_level_start} = 0, \text{operator_level_max} = 5$ 。搜索从若干紧凑种子结构初始化, 包括 `[[id]]`、`[[id, square]]`、`[[id, square, cube]]` 和 `[[sin]]`。

主要实验在 RTX 4090 上运行, 采用 15 个并行任务, 每个任务 1200 秒时间预算。实践中, EQL-Z 在由小到大的搜索中平均评估约 50 个候选结构, 实际运行时间约为 10 分钟到 6 小时, 取决于任务难度和搜索进展。在 SRBench 黑盒设置中, 我们每个数据集使用 10 分钟受限预算, 因此这些结果应理解为短预算性能, 而非长时程 SRBench 协议的复现。

(2) 三种初始化方案 在所有比较中, 我们对 EQL 类模型使用三种初始化方案: `default`、`ones` 和 `scaled`。**default 初始化** 从小方差零均值高斯分布中采样所有线性权重, 并将所有偏置设为 0, 对应标准 MLP 初始化。它作为自然基线, 但不显式考虑符号算子输出尺度或层间激活分布。

ones 初始化将所有权重设为 1、所有偏置设为 0，使所有连接在训练初始同等贡献。我们主要用它研究在“相同初始系数和固定结构”下算子选择、剪枝与零点约束的敏感性，而不是作为性能优化初始化。**scaled 初始化（逐层 RMS 校准初始化）**旨在在不改变网络拓扑或算子集合的前提下，使各层和算子块的预激活及算子输出 RMS 尺度保持在可控范围内。这提高了训练稳定性，并降低某些算子在最开始被“过度点燃”的风险。

具体而言，**scaled** 初始化包含两步。(i) 逐层缩放：对每个线性层，先构造一组“探针样本”（例如从数据定义域 $[x_{\min}, x_{\max}]$ 或 $[-1, 1]$ 中均匀采样），通过线性映射得到预激活 z 。随后按“算子块”（例如与同一元或二元算子族相关的列）分组输出，计算每个块的 RMS，并重缩放权重矩阵的对应行，使每个块的 RMS 匹配目标尺度。这样，每个算子块在施加非线性符号算子前都具有合理数值尺度。(ii) 递归跨层缩放：校准一层后，将其符号算子作用于缩放后的预激活以得到新激活，再将这些激活作为下一层输入并重复相同过程。这种自顶向下的递归校准约束了跨深度的线性映射和符号输出尺度，缓解“中间层激活爆炸”或“深层激活接近零”等问题。总体而言，**scaled** 初始化在不改变架构或算子集合的情况下，为激活分布提供“结构感知”的预归一化；它稳定梯度传播，并与零点约束共同进一步抑制冗余算子的虚假激活。除非另有说明，正文中所有 EQL(-Z) 结果均在这三种初始化方案上多次运行取平均。

(3) 多个初始结构与重复运行 在方程恢复实验中，我们为 EQL-Z 设计多个起始算子结构，以减少单个初始架构造成的偏差。典型起始结构包括简单单层结构，如 `[[id]]` 和 `[[sin]]`；轻量多项式结构，如 `[[id, square]]`；以及若干结合基本多项式和三角算子的混合结构。对于每个候选起始结构和每种初始化方案（`default`、`ones`、`scaled`），我们用不同随机种子运行 10 次独立试验。所有报告的恢复率和性能指标均由这些重复运行计算得到。

(4) 结构选择与由小到大策略的作用 由小到大结构搜索策略的核心作用不仅是缩小搜索空间，还在于帮助模型自动发现与目标任务匹配的算子-层结构，从而恢复更接近真实公式的紧凑表达式。经验上，我们发现直接使用包含大量算子的固定大型架构（例如一次性堆叠宽层）常导致 EQL 类模型激活大量冗余项，即使算子库已经足以表示目标。所得表达式往往过于复杂且可解释性较差。相比之下，从紧凑架构出发并通过局部增宽和加深逐步增长时，EQL-Z 在搜索过程中更可靠地收敛到合理的算子组合和层布局。例如，在某些 Nguyen 函数上，结构搜索经过若干局部增长步骤后，会收敛到如下两层架构：

$$[[id, square, cube], [log_reg]],$$

其中第一层由多项式基算子组成，第二层包含单个对数算子。在该结构下，EQL-Z 能够完整恢复目标表达式。这些观察强调，结构设计和算子层组合对于成功方程恢复与算子库本身同样关键。零点约束和缩放初始化在梯度和尺度层面提供稳定性，而由小到大策略在架构空间中逐步过滤与任务不匹配的结构。这些组件的结合使 EQL-Z 能找到更紧凑、与真实结构更接近的解析结构，从而显著提升方程恢复率。

F 补充图表

图 9 比较了 EQL-Z 与基线方法在带真实公式基准上的表现，显示 EQL-Z 在表达式复杂度显著更低的同时取得了较强精度；相较原始 EQL，它同时获得更高精度和大幅降低的复杂度。表 6 报告了 Nguyen 恢复基准上完整组件级 20 次运行消融。表 2 报告了真实世界任务上的 ID/OOD

表 5: Nguyen 基准上的消融研究。

Method	R2	ACC01	ACC001	Complexity
EQL	0.998 ± 0.000	0.937 ± 0.002	0.574 ± 0.066	776.6
EQL-Z _{w/oSTL}	0.996 ± 0.012	0.898 ± 0.261	0.683 ± 0.340	70.4
EQL-Z _{w/oZP}	0.995 ± 0.018	0.956 ± 0.132	0.838 ± 0.379	16.7
EQL-Z	1.000 ± 0.000	1.000 ± 0.000	1.000 ± 0.000	17.5

表 6: 12 个标准 Nguyen 基准上完整的 20 次运行组件级精确恢复率。“w/o ZP”、“w/o STL”和“w/o BFGS”分别表示从完整 EQL-Z 流程中移除零点约束、由小到大结构搜索和 BFGS 精修步骤。最后四列隔离了基于原始 EQL 骨干的单组件变体。

Benchmark	EQL-Z	w/o ZP	w/o STL	w/o BFGS	STL only	BFGS only	ZP only	EQL	ParFam [†]
Nguyen-1	100%	100%	60%	100%	100%	20%	60%	0%	100%
Nguyen-2	100%	100%	30%	100%	100%	10%	10%	0%	100%
Nguyen-3	100%	95%	10%	100%	90%	0%	5%	0%	100%
Nguyen-4	100%	90%	0%	100%	80%	0%	0%	0%	100%
Nguyen-5	80%	60%	0%	25%	0%	0%	0%	0%	83%
Nguyen-6	100%	100%	0%	100%	65%	0%	0%	0%	83%
Nguyen-7	100%	0%	0%	100%	0%	0%	0%	0%	100%
Nguyen-8	100%	100%	100%	100%	100%	100%	100%	0%	100%
Nguyen-9	100%	95%	0%	100%	80%	0%	0%	0%	100%
Nguyen-10	100%	100%	0%	75%	70%	0%	0%	0%	100%
Nguyen-11	100%	100%	0%	30%	5%	0%	0%	0%	0%
Nguyen-12	100%	90%	15%	100%	45%	0%	0%	0%	100%
Average	98.3%	86.3%	17.9%	77.5%	61.3%	10.8%	14.6%	0.0%	88.8%

NMSE; EQL-Z 持续优于原始 EQL，并与其他非 LLM 符号回归基线具有竞争力，但仍低于使用大语言模型先验的 LLM-SR 方法。

表 6 进一步分解了各组件的贡献。在单组件变体中，STL only 取得最高平均恢复率 (61.3%)，确认了控制结构扩展是该基准上精确恢复的主导因素。不过，ZP only 与原始 EQL 的比较表明，零点约束单独使用也有效：在相同骨干、无由小到大搜索或 BFGS 精修时，加入零点一致算子将平均恢复率从 0.0% 提升到 14.6%。这说明零点一致性并非结构搜索的次级效应，而是通过减少冗余算子路径的持续干扰，直接改变了 EQL 的优化行为。最后，BFGS only 将恢复率提升到 10.8%，说明当符号结构尚未接近目标时，仅靠数值精修是不够的。当三个组件结合时取得最强结果，表明 STL、ZP 和 BFGS 分别作用于恢复流程的不同阶段。

G 记忆建模实验

为进一步评估 EQL-Z 在真实世界任务上的适应性，我们在 MaiMemo 记忆数据集上进行回忆概率预测实验。该数据集来自单词学习平台墨墨背单词 (MaiMemo) [?]，其目标是提供高效的词汇学习和复习策略，以改善用户记忆效果。在学习过程中，MaiMemo 记录用户的复习行为，




图 9: EQL-Z 与基线方法在带真实公式数据集上的性能和复杂度比较。

表 7: MaiMemo 记忆数据集的特征说明。

Feature Name	Description
Word Difficulty d	当前单词的内在难度
Previous Review Interval Δt	距该词上一次复习的时间间隔
Total Interval Sum $\sum \Delta t$	所有历史复习间隔的累计和
Total Review Count n	该词被复习的总次数
User Proficiency u	用户对该词的当前熟练度
Last Recall Success s	上一次复习是否成功的指示变量（成功则 $s = 1$ ）
Weighted Success Rate $\hat{r}_w$	时间衰减加权回忆成功率
Overall Success Rate $\hat{r}$	整个复习历史中的成功回忆比例
Predicted Probability $\hat{y}$	当前复习中成功回忆的预测概率（目标）

包括单词难度、学习轨迹、复习间隔、回忆结果以及系统预测的回忆概率。与 PMLB 等标准基准相比，MaiMemo 更接近真实记忆建模场景，非常适合探索用户认知行为背后的数学结构。

为保证数据质量，我们仅保留相同条件下至少有 100 个观测的样本，从而过滤由噪声或极端个体差异引起的不稳定情形。随后，我们进行系统性特征工程，包括异常值移除（例如丢弃 $\hat{y} = 0$ 或 $\hat{y} = 1$ 的样本）、变量变换和统计特征构造。表 7 总结的核心建模变量覆盖复习间隔、用户熟练度和回忆成功率等关键因素，这些因素共同刻画记忆行为的基本方面。

我们将 EQL-Z 与若干基线模型比较，包括 Half-Life Regression (HLR) 模型 [?]、Wickelgren 记忆模型 [?]、端到端回归模型 (E2E) 以及基于树的符号回归模型 (TPSR)。HLR 假设记忆随时间指数衰减，其函数形式为

$$\hat{y} = \exp\left(-\frac{\ln 2 \cdot t}{h}\right),$$

其中 h 表示记忆半衰期，即回忆概率衰减到 0.5 所需时间。Wickelgren 模型则假设幂律衰减：

$$\hat{y} = \lambda \cdot t^{-\psi},$$

其中 λ 和 ψ 为可学习参数。我们使用均方误差 (MSE)、均方根误差 (RMSE) 和平均绝对误差 (MAE) 作为评估指标。实验结果见表 8。

从结果可见，EQL-Z 在 RMSE、MAE 和 MSE 三个指标上均优于传统记忆模型和现有符号回归方法。这表明 EQL-Z 在保持高度结构紧凑性的同时，更能够捕捉个体化记忆模式。

表 8: 不同模型在 MaiMemo 数据集上的性能和学习公式。

Model	RMSE	MAE	MSE	Predicted Formula
EQL-Z	0.07127	0.05736	0.0051	$\hat{y} = 0.457 \cdot \exp(0.124x_3 - 0.079x_4) + 0.412$
HLR	0.2128	0.1618	0.0453	$\hat{y} = \frac{x_2}{2^{-0.0380x_0+2.017x_1+0.3162x_3} + 0.0418x_4 - 0.4145x_5 + 0.6889}$
Wick	0.1267	0.0999	0.0160	$\hat{y} = 0.7713 \cdot (1 + 1.7040x_1)^{0.0255}$
E2E	0.0898	0.0664	0.0081	$\hat{y} = 0.98 - 0.00854 \cdot \sqrt{ ABC } + 0.00667,$
				$A = 0.00078x_3 - 6.037x_6 + 100.872,$
				$B = 0.732x_5 - 5.888x_7 + 3.624,$
				$C = 0.0325x_1 - 0.0217x_2 + 0.3565x_4$
TPSR	0.6090	0.5957	0.3709	$- 3.0 \cdot \cos(102.67x_0 - 220.97) + 0.456$
				$\hat{y} = \frac{0.9}{0.1 + 8.99 - 0.001/(0.015 + 0.051) - 5.0/x_3}$

参考文献

- [1] Sören Becker, Michal Klein, Alexander Neitz, Giambattista Parascandolo, and Niki Kilbertus. Predicting ordinary differential equations with transformers. In *International conference on machine learning*, pages 1978–2002. PMLR, 2023.
- [2] Tommaso Bendinelli, Luca Biggio, and Pierre-Alexandre Kamienny. Controllable neural symbolic regression. In *International Conference on Machine Learning*, pages 2063–2077. PMLR, 2023.
- [3] Luca Biggio, Tommaso Bendinelli, Alexander Neitz, Aurelien Lucchi, and Giambattista Parascandolo. Neural symbolic regression that scales. In *International Conference on Machine Learning*, pages 936–945. Pmlr, 2021.
- [4] Yu Cheng, Duo Wang, Pan Zhou, and Tao Zhang. A survey of model compression and acceleration for deep neural networks. *arXiv preprint arXiv:1710.09282*, 2017.
- [5] Cristina Cornelio, Sanjeeb Dash, Vernon Austel, Tyler R Josephson, Joao Goncalves, Kenneth L Clarkson, Nimrod Megiddo, Bachir El Khadir, and Lior Horesh. Combining data and theory for derivable scientific discovery with ai-descartes. *Nature Communications*, 14(1):1777, 2023.
- [6] Wei Deng, Lijun Liu, Xiaohang Li, Yanyu Huang, Ming Hu, Yafang Zheng, Yuan Yin, Yan Huan, Shuxun Cui, Zhaoyan Sun, et al. Machine-learning-enhanced trial-and-error for efficient optimization of rubber composites. *Advanced Materials*, 37(16):2407763, 2025.
- [7] Owen Dugan, Rumen Dangovski, Allan Costa, Samuel Kim, Pawan Goyal, Joseph Jacobson, and Marin Soljačić. Occamnet: A fast neural model for symbolic regression at scale. *arXiv preprint arXiv:2007.10784*, 2020.

- [8] Torsten Hoeffler, Dan Alistarh, Tal Ben-Nun, Nikoli Dryden, and Alexandra Peste. Sparsity in deep learning: Pruning and growth for efficient inference and training in neural networks. *Journal of Machine Learning Research*, 22(241):1–124, 2021.
- [9] Pierre-Alexandre Kamienny, Stéphane d’Ascoli, Guillaume Lample, and François Charton. End-to-end symbolic regression with transformers. *Advances in Neural Information Processing Systems*, 35:10269–10281, 2022.
- [10] Michael Kommenda, Bogdan Burlacu, Gabriel Kronberger, and Michael Affenzeller. Parameter identification for symbolic regression using nonlinear least squares. *Genetic Programming and Evolvable Machines*, 21(3):471–501, 2020.
- [11] Jiří Kubalík, Erik Derner, and Robert Babuška. Toward physically plausible data-driven models: A novel neural network approach to symbolic regression. *IEEE Access*, 11:61481–61501, 2023.
- [12] William La Cava, Bogdan Burlacu, Marco Virgolin, Michael Kommenda, Patryk Orzechowski, Fabrício Olivetti de França, Ying Jin, and Jason H Moore. Contemporary symbolic regression methods and their relative performance. *Advances in neural information processing systems*, 2021(DB1):1, 2021.
- [13] Mikel Landajuela, Chak Shing Lee, Jiachen Yang, Ruben Glatt, Claudio P Santiago, Ignacio Aravena, Terrell Mundhenk, Garrett Mulcahy, and Brenden K Petersen. A unified framework for deep symbolic regression. *Advances in Neural Information Processing Systems*, 35:33985–33998, 2022.
- [14] Haoran Li, Yang Weng, and Hanghang Tong. Console: Convex neural symbolic learning. *Advances in Neural Information Processing Systems*, 35:5766–5774, 2022.
- [15] Qingliang Li, Cheng Zhang, Zhongwang Wei, Xiaochun Jin, Wei Shangguan, Hua Yuan, Jinlong Zhu, Lu Li, Pingping Liu, Xiao Chen, et al. Advancing symbolic regression for earth science with a focus on evapotranspiration modeling. *npj Climate and Atmospheric Science*, 7(1):321, 2024.
- [16] Wenqiang Li, Weijun Li, Linjun Sun, Min Wu, Lina Yu, Jingyi Liu, Yanjie Li, and Songsong Tian. Transformer-based model for symbolic regression via joint supervised learning. In *The Eleventh International Conference on Learning Representations*, 2022.
- [17] Wenqiang Li, Weijun Li, Lina Yu, Min Wu, Linjun Sun, Jingyi Liu, Yanjie Li, Shu Wei, Yusong Deng, and Meilan Hao. A neural-guided dynamic symbolic network for exploring mathematical expressions from data. *arXiv preprint arXiv:2309.13705*, 2023.
- [18] Mohammad Loni, Aditya Mohan, Mehdi Asadi, and Marius Lindauer. Learning activation functions for sparse neural networks. In *International Conference on Automated Machine Learning*, pages 16–1. PMLR, 2023.
- [19] Nour Makke and Sanjay Chawla. Interpretable scientific discovery with symbolic regression: a review. *Artificial Intelligence Review*, 57(1):2, 2024.

- [20] Georg Martius and Christoph H Lampert. Extrapolation and learning equations. *arXiv preprint arXiv:1610.02995*, 2016.
- [21] Yoshitomo Matsubara, Naoya Chiba, Ryo Igarashi, and Yoshitaka Ushiku. Rethinking symbolic regression datasets and benchmarks for scientific discovery. *arXiv preprint arXiv:2206.10540*, 2022.
- [22] Terrell Mundhenk, Mikel Landajuela, Ruben Glatt, Claudio P Santiago, Brenden K Petersen, et al. Symbolic regression via deep reinforcement learning enhanced genetic programming seeding. *Advances in Neural Information Processing Systems*, 34:24912–24923, 2021.
- [23] Vinod Nair and Geoffrey E Hinton. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th international conference on machine learning (ICML-10)*, pages 807–814, 2010.
- [24] Tomasz P Pawlak, Bartosz Wieloch, and Krzysztof Krawiec. Semantic backpropagation for designing search operators in genetic programming. *IEEE Transactions on Evolutionary Computation*, 19(3):326–340, 2014.
- [25] Brenden K Petersen, Mikel Landajuela, T Nathan Mundhenk, Claudio P Santiago, Soo K Kim, and Joanne T Kim. Deep symbolic regression: Recovering mathematical expressions from data via risk-seeking policy gradients. *arXiv preprint arXiv:1912.04871*, 2019.
- [26] Patrick AK Reinbold, Logan M Kageorge, Michael F Schatz, and Roman O Grigoriev. Robust learning from noisy, incomplete, high-dimensional experimental data via physically constrained symbolic regression. *Nature communications*, 12(1):3219, 2021.
- [27] Subham Sahoo, Christoph Lampert, and Georg Martius. Learning equations for extrapolation and control. In *International Conference on Machine Learning*, pages 4442–4450. Pmlr, 2018.
- [28] Parshin Shojaee, Kazem Meidani, Amir Barati Farimani, and Chandan Reddy. Transformer-based planning for symbolic regression. *Advances in Neural Information Processing Systems*, 36:45907–45919, 2023.
- [29] Alexander Topchy, William F Punch, et al. Faster genetic programming based on local gradient search of numeric leaf values. In *Proceedings of the genetic and evolutionary computation conference (GECCO-2001)*, volume 155162. Morgan Kaufmann San Francisco, CA, 2001.
- [30] Silviu-Marian Udrescu, Andrew Tan, Jiahai Feng, Orisvaldo Neto, Tailin Wu, and Max Tegmark. Ai feynman 2.0: Pareto-optimal symbolic regression exploiting graph modularity. *Advances in Neural Information Processing Systems*, 33:4860–4871, 2020.
- [31] Silviu-Marian Udrescu and Max Tegmark. Ai feynman: A physics-inspired method for symbolic regression. *Science advances*, 6(16):eaay2631, 2020.
- [32] Nguyen Quang Uy, Nguyen Xuan Hoai, Michael O’Neill, Robert I McKay, and Edgar Galván-López. Semantically-based crossover in genetic programming: application to real-valued symbolic regression. *Genetic Programming and Evolvable Machines*, 12:91–119, 2011.

- [33] Marco Virgolin, Tanja Alderliesten, Cees Witteveen, and Peter AN Bosman. Improving model-based genetic programming for symbolic regression of small expressions. *Evolutionary computation*, 29(2):211–237, 2021.
- [34] Matthias Werner, Andrej Junginger, Philipp Hennig, and Georg Martius. Informed equation learning. *arXiv preprint arXiv:2105.06331*, 2021.
- [35] Min Wu, Weijun Li, Lina Yu, Wenqiang Li, Jingyi Liu, Yanjie Li, and Meilan Hao. Prunesymnet: A symbolic neural network and pruning algorithm for symbolic regression. *arXiv preprint arXiv:2401.15103*, 2024.
- [36] Hongpeng Zhou and Wei Pan. Bayesian learning to discover mathematical operations in governing equations of dynamic systems. *arXiv preprint arXiv:2206.00669*, 2022.